

$$E_{\theta, \tilde{\theta} \sim \pi} [G(\theta, \tilde{\theta})] - 1 = E_{\theta, \tilde{\theta} \sim \pi} \left[E_Q \left[\frac{P_{\theta} P_{\tilde{\theta}}}{Q^2} \right] \right] - 1$$

$$= \int_{\Theta} \pi(\theta) d\theta \int_{\tilde{\Theta}} \pi(\tilde{\theta}) d\tilde{\theta} \int_X Q(x) \frac{P_{\theta}(x) P_{\tilde{\theta}}(x)}{Q^2(x)} dx - 1$$

$$= \int_X \left(\frac{dx}{Q(x)} \int_{\Theta} P_{\theta}(x) \pi(\theta) d\theta \times \int_{\tilde{\Theta}} P_{\tilde{\theta}}(x) \pi(\tilde{\theta}) d\tilde{\theta} \right) - 1 = \int_X \frac{dx}{Q(x)} \times P_{\pi}(x) \times P_{\pi}(x) - 1$$

$$= \int_X \frac{P_{\pi}^2(x)}{Q(x)} dx - 1 = \chi^2(P_{\pi} \parallel Q)$$

سوال (۲) (۲) بزرگن خلف، فرض کنید دنباله A_n وجود دارد که به ازای آن $Q_n(A_n) \xrightarrow{n \rightarrow \infty} 0$ و $P_n(A_n) \xrightarrow{n \rightarrow \infty} a$ صفر نیست. داریم،

$$\chi^2(P_n \parallel Q_n) = \int \frac{P_n^2(x)}{Q_n(x)} dx - 1 \geq \int_{A_n} \frac{P_n^2(x)}{Q_n(x)} dx - 1$$

$$\int_{A_n} \frac{P_n^2(x)}{Q_n(x)} dx \times \int_{A_n} Q_n(x) dx \geq \left(\int_{A_n} P_n(x) dx \right)^2 \Rightarrow \int_{A_n} \frac{P_n^2(x)}{Q_n(x)} dx \geq \frac{P_n^2(A_n)}{Q_n(A_n)}$$

$$\Rightarrow \chi^2(P_n \parallel Q_n) \geq \frac{P_n^2(A_n)}{Q_n(A_n)} - 1 \Rightarrow \lim_{n \rightarrow \infty} \chi^2(P_n \parallel Q_n) \geq \lim_{n \rightarrow \infty} \frac{P_n^2(A_n)}{Q_n(A_n)} - 1 = +\infty$$

که خلاف فرض (۱) $\chi^2(P_n \parallel Q_n) = O(1)$ است. فرض خلف باطل.

سوال (۲) (۱) برای حل، روی σ_i و $\hat{\sigma}_i$ و $\hat{\sigma}_i$ و $\hat{\sigma}_i$ حالت بندی می کنیم.
که k_1 تا k_ϵ ، تعداد این حالت ها را نشان می دهد:

$\sigma_i = \hat{\sigma}_i$	$\sigma_i \neq \hat{\sigma}_i$
k_1	k_ϵ
k_ϵ	k_ϵ

حال $G(\sigma, \hat{\sigma})$ را می سب می کنیم:

$$G(\sigma, \hat{\sigma}) = \int \frac{P_\sigma P_{\hat{\sigma}}}{P_0} (G) dG = \int \prod_{i=1}^n \frac{P_\sigma P_{\hat{\sigma}}}{P_0} (G_{ij}) dG_{ij} \quad \text{استقلال}$$

$$= \prod_{i=1}^n \int \frac{P_\sigma P_{\hat{\sigma}}}{P_0} (G_{ij}) dG_{ij} = \left(\int \frac{2P^2}{P+Q} \right)^{k_1} \left(\int \frac{2Q^2}{P+Q} \right)^{k_\epsilon} \left(\int \frac{2PQ}{P+Q} \right)^{k_\epsilon + k_\epsilon}$$

بر اساس حالت های σ و $\hat{\sigma}$ که در بالا تقسیم، P و Q جایگزین کردیم. حال مقدار این انتگرال ها را محاسبه می کنیم.

$$2 \int \frac{P^2}{P+Q} = 2 \int \frac{(P+Q)^2 - 2PQ}{P+Q} = 2 \int (P - \frac{PQ}{P+Q}) = 2 \int P - \int \frac{2PQ}{P+Q} = 2 - \int \frac{2PQ}{P+Q}$$

به طور مشابه $\int \frac{2Q^2}{P+Q} = 2 - \int \frac{2PQ}{P+Q}$ پس $\int \frac{2PQ}{P+Q}$ را بر حسب P به دست می آوریم.

$$P = \int \frac{(P-Q)^2}{2(P+Q)} = \int \frac{P^2 + Q^2 + 2PQ - 4PQ}{2(P+Q)} = \int \frac{1}{2} (P+Q) - \int \frac{2PQ}{P+Q}$$

$$\Rightarrow \int \frac{2PQ}{P+Q} = \boxed{1-P} \Rightarrow \int \frac{2P^2}{P+Q} = \int \frac{2Q^2}{P+Q} = 2 - (1-P) = \boxed{1+P}$$

$$\Rightarrow G(\sigma, \hat{\sigma}) = (1-P)^{k_\epsilon + k_\epsilon} (1+P)^{k_1 + k_\epsilon} \rightarrow k \triangleq k_1 + k_\epsilon \Rightarrow k_1 + k_\epsilon = \frac{n}{2} - k$$

که چون ماتریس قرینه است، نصف حالت ها را نمایم.
حال k را محاسبه می کنیم (ایده ای این محاسبه از کسری خوشبو):

$$k = |\{ \sigma_i \oplus \hat{\sigma}_i \oplus \sigma_i \oplus \hat{\sigma}_i = 1 \}|$$

$$\Rightarrow \sum_{\sigma \oplus \hat{\sigma}} (\sigma_i \oplus \hat{\sigma}_i) (\sigma_i \oplus \hat{\sigma}_i) = 1 \quad \text{یعنی در یک نقطه مساوی باشند و در یک نقطه نه}$$

$$\Rightarrow k = d_H(\sigma, \hat{\sigma}) (n - d_H(\sigma, \hat{\sigma}))$$

$$\text{هم چنین می دانیم } \langle \sigma, \hat{\sigma} \rangle = n - 2d_H(\sigma, \hat{\sigma}) \quad \text{پس } d_H = \frac{1}{2} (n - \langle \sigma, \hat{\sigma} \rangle)$$

$$k = \frac{1}{\gamma} (n - \langle \sigma, \hat{\sigma} \rangle) \times \frac{1}{\gamma} (n + \langle \sigma, \hat{\sigma} \rangle) = \frac{1}{\varepsilon} (n^2 - \langle \sigma, \hat{\sigma} \rangle^2)$$

$$\Rightarrow k_1 + k_\varepsilon = \frac{n^2}{\gamma} - k = \frac{1}{\varepsilon} (n^2 + \langle \sigma, \hat{\sigma} \rangle^2)$$

$$G(\sigma, \hat{\sigma}) = (1-p)^k (1+p)^{\frac{n^2}{\gamma} - k} \stackrel{(*)}{\leq} \exp\left(-p\left(\frac{n^2 - \langle \sigma, \hat{\sigma} \rangle^2}{\varepsilon}\right) + p\left(\frac{n^2 + \langle \sigma, \hat{\sigma} \rangle^2}{\varepsilon}\right)\right) \stackrel{\text{بنابرین}}{=} \\ = \exp\left(\frac{p}{\gamma} \langle \sigma, \hat{\sigma} \rangle^2\right)$$

که در $(*)$ از نامساوی $(1-x) \leq e^{-x}$ که در سوال بعد آمده استفاده کردیم.

$$P = \sum \frac{(P-Q)^2}{\gamma(P+Q)} = \frac{\left(\frac{a-b}{n}\right)^2}{\gamma\left(\frac{a+b}{n}\right)} + \frac{\left(1 - \frac{a}{n} + 1 - \frac{b}{n}\right)^2}{\gamma\left(2 - \frac{a+b}{n}\right)} = \frac{1}{\gamma n} (a-b)^2 \left[\frac{1}{a+b} + \frac{1}{2n - (a+b)} \right] \quad (2) \\ = \frac{\pi}{n} + \frac{1}{\gamma(2n - a - b)} = \frac{\pi + o(1)}{n}$$

همانطور که می دانیم $\frac{1}{\gamma(2n - a - b)} \in o(1)$ است.

(3) می خواهیم نشان دهیم P_0, P_1 از هم قابل تمیز نیستند. برای این کار نشان می دهیم فاصله χ^2 بین این دو توزیع وقتی $n \rightarrow \infty$ می رود، صفر است.

می دانیم P_1 میانگین P_0 می باشد (مانند P_π در سوال ۱) پس داریم:

$$\chi^2(P_1 \| P_0) = \mathbb{E}_{\sigma, \hat{\sigma}} [G(\sigma, \hat{\sigma})] - 1 \quad \text{and} \quad G(\sigma, \hat{\sigma}) = \mathbb{E}_{P_0} \left[\frac{P_\sigma P_{\hat{\sigma}}}{P_0} \right] = \int \frac{P_\sigma P_{\hat{\sigma}}}{P_0}$$

$$G(\sigma, \hat{\sigma}) \leq \exp\left(\frac{P}{2} \langle \sigma, \hat{\sigma} \rangle^2\right) \quad \text{و در بخش ۱ نشان دادیم، پس}$$

$$\chi^2 \leq \mathbb{E}_{\sigma, \hat{\sigma}} \left[\exp\left(\frac{P}{2} \langle \sigma, \hat{\sigma} \rangle^2\right) \right] - 1$$

حال می توان $\langle \sigma, \hat{\sigma} \rangle$ را به صورت جمع تعدادی متغیر برنزی در نظر گرفت:

$$\langle \sigma, \hat{\sigma} \rangle = \sum_i \sigma_i \hat{\sigma}_i \quad P(\sigma_i \hat{\sigma}_i = 1) = P(\sigma_i \hat{\sigma}_i = -1) = \frac{1}{4} \quad (2 \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{4})$$

$$\text{Var}(\sigma_i \hat{\sigma}_i) = 2^2 \times p \times (1-p) = 4 \times \frac{1}{4} = 1$$

فاصلی (مقدار برنزی)

پس در $n \rightarrow \infty$ می توان $\langle \sigma, \hat{\sigma} \rangle$ را یک متغیر گاوسی در نظر گرفت! یا دقیق تر:

$$\lim_{n \rightarrow \infty} \frac{1}{\sqrt{n}} \langle \sigma, \hat{\sigma} \rangle \sim \mathcal{N}(0, 1) \quad (\text{قضیه حد مرکزی})$$

$$\lim_{n \rightarrow \infty} \chi^2(P_1 \| P_0) \leq \lim_{n \rightarrow \infty} \mathbb{E}_{Z \sim \mathcal{N}(0, 1)} \left[\exp\left(\frac{P}{2} \times n \times Z^2\right) \right] - 1 \quad \text{پس داریم:}$$

$$= \lim_{n \rightarrow \infty} \mathbb{E}_Z \left[\exp\left(\frac{P}{2} (\tau + o(1)) Z^2\right) \right] - 1 = \mathbb{E}_{Z \sim \mathcal{N}} \left[\exp\left(\frac{\tau Z^2}{2}\right) \right] - 1$$

$$= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} e^{\frac{\tau z^2}{2}} dz - 1 = \frac{\sigma}{\sigma \sqrt{2\pi}} \int_{-\infty}^{+\infty} \frac{\sigma}{\sigma \sqrt{2\pi}} e^{-\frac{z^2}{2\sigma^2}} dz - 1 = \sigma - 1$$

$$= \frac{1}{\sqrt{\tau-1}} - 1 = o(1)$$

بنابراین طبق قسمت (۲) سوال (۱)، $P_1 \not\leq P_0$ و بنابراین نمی توان آن را از هم تمیز داد.

سوال (۳) (۱) طبق تعریف ML باید به ما بگوید
 رابطه خاصی دهدهد که می توان آن را ساده تر کرد

$$\hat{M}_{ML} \in \arg \max_M \prod_{e \in M} P(w_e) \prod_{e \notin M} Q(w_e)$$

لگاریتم بگیریم
 $\rightarrow = \arg \max_M \log \left(\prod_{e \in M} P(w_e) \prod_{e \notin M} Q(w_e) \right)$

اضافه کنیم

$$= \arg \max_M \sum_{e \in M} \log P(w_e) + \sum_{e \notin M} \log Q(w_e) + \sum_{e \in M} \log Q(w_e) - \sum_{e \in M} \log Q(w_e)$$

$$= \arg \max_M \sum_{e \in M} \log \frac{P}{Q}(w_e) + \sum_{e \notin M} \log Q(w_e) = \arg \max_M \sum_{e \in M} \log \frac{P}{Q}(w_e)$$

منتقل از انتخاب M

(۲) ابتدا باید مورد نیاز برای $\binom{n}{k} k!$ را حساب می کنیم

$$\binom{n}{k} k! = \frac{n!}{(n-k)!} = \prod_{j=0}^{k-1} (n-j)$$

$$= n^k \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right) = n^k \prod_{j=0}^{k-1} e^{-j/n} = n^k e^{-\frac{k^2-k}{2n}} = \exp\left(k \log n - \frac{k^2}{2n} + \frac{k}{2n}\right)$$

اکنون احتمال آن را حساب می کنیم که $\frac{1}{4} |M^* \Delta \hat{M}_{ML}| \geq \beta n$ باشد (ما به این نتیجه رسیدیم که برای اثبات این حکم باید $\frac{1}{4}$ قضاصل متفاوت را در نظر گرفت. یعنی تعداد یال هایی که از M^* در \hat{M}_{ML} نیامده)
 برای محاسبه این احتمال، همی $\frac{1}{4} |M^* \Delta \hat{M}_{ML}| = k$ به ازای $n \geq k \geq \beta n$ را در نظر می گیریم. برای محاسبه این احتمال نیز یک حالت دلخواه \hat{M} را در نظر می گیریم و ضربدر حد اکثر تعداد حالات مجاز می کنیم.

$$P\left[\frac{1}{4} |M^* \Delta \hat{M}_{ML}| \geq \beta n\right] = \sum_{k=\beta n}^n P\left[\frac{1}{4} |M^* \Delta \hat{M}_{ML}| = k\right] \leq \sum_{k=\beta n}^n \binom{n}{k} k! P\left[\frac{1}{4} |M^* \Delta \hat{M}| = k\right]$$

که حال برای باند زدن وای این احتمال، از نامساوی انحراف بزرگ استفاده می کنیم (که حالت خاص آن که در سوال ۲ تمرین ۱ اثبات شد) می دانیم وقتی $\frac{1}{4} |M^* \Delta \hat{M}| = k$ باشد، یعنی جمع $\log \frac{P}{Q}$ در k تا یال در \hat{M} که در تطابق نبوده اند (از توزیع Q بودند) از k تا یال در M^* (از توزیع P) بیشتر بوده است که انتخاب شده اند یا به عبارتی

$$\sum_{i=1}^k Y_i \geq \sum_{i=1}^k X_i \Leftrightarrow \sum_{i=1}^k Y_i - X_i \geq 0 \quad \begin{matrix} Y_i = \log \frac{P(\eta_i)}{Q(\eta_i)}, \eta_i \sim Q \\ X_i = \log \frac{P(\eta_i)}{Q(\eta_i)}, \eta_i \sim P \end{matrix}$$

$$P\left[\sum_{i=1}^k Y_i - X_i \geq 0\right] \leq \exp(2k \log B)$$

و طبق تمرین قبل می دانیم

که $BC(p, q)$ است. پس با استفاده از این موضوع،

$$P\left[\frac{1}{r} |M^* - \hat{M}_{ML}| \geq \beta n\right] \leq \sum_{k=\beta n}^n \binom{n}{k} \kappa! \cdot P\left[\sum_{i=1}^k Y_i - X_i \geq 0\right]$$

$$\rightarrow \leq \sum_{k=\beta n}^n \exp\left(k \log n - \frac{k^r}{rn} + \frac{k}{rn} + 2k \log B\right)$$

$$\leq \sum_{k=\beta n}^n \exp\left(k \log n - \frac{k^r}{rn} + \frac{k}{rn} + 2k \log(1+\varepsilon) - k \log n\right)$$

$$\leq \sum_{k=\beta n}^n \exp\left(\frac{-k^r}{rn} + \frac{k}{rn} + \frac{k\beta}{\varepsilon}\right)$$

$$\leq \sum_{k=\beta n}^n \exp\left(\frac{-k\beta}{r} + \frac{1}{r} + \frac{k\beta}{\varepsilon}\right)$$

$$= e^{\frac{1}{r}} \sum_{k=\beta n}^n \exp\left(\frac{-k\beta}{\varepsilon}\right) \leq e^{\frac{1}{r}} \sum_{k=\beta n}^{\infty} \exp\left(\frac{-k\beta}{\varepsilon}\right)$$

$$= e^{\frac{1}{r}} \times \frac{\exp\left(\frac{-\beta n}{\varepsilon}\right)}{1 - \exp\left(\frac{-\beta}{\varepsilon}\right)}$$

$$B \leq \frac{1+\varepsilon}{\sqrt{n}} \rightarrow \log B \leq \log(1+\varepsilon) - \frac{1}{r} \log n$$

$$\beta \geq \frac{1}{\log(1+\varepsilon)} \Rightarrow 2 \log(1+\varepsilon) \leq \frac{\beta}{\varepsilon}$$

$$k \leq n \Rightarrow \frac{k}{rn} \leq \frac{1}{r}$$

$$k \geq \beta n \Rightarrow \frac{k^r}{rn} \geq \frac{k\beta}{r}$$

$$\Rightarrow \frac{-k^r}{rn} \leq \frac{-k\beta}{r}$$

$$\beta n \leq n \Rightarrow \beta \leq 1 \Rightarrow e^{\frac{-\beta}{\varepsilon}} \leq 1$$

مقدار نسبت

مقدار نسبت

(۳)

(۱) می دانیم بهترین خطای در آزمون فرض می توان به دست آورد $\frac{1}{4}(1 - TV(P||Q_\theta))$ است.

بنابراین تعیین کمترین خطای معادل به دست آوردن TV است که یک f -div به صورت

روبرو است.

$$TV(P, Q_\theta) = \sup_f \mathbb{E}_P[f(x)] - \mathbb{E}_{Q_\theta}[f(x)]$$

یا به عبارت دیگر،

$$f(x) = \frac{1}{4} |x-1| \Rightarrow D_f(P, Q) = TV(P, Q)$$

(۲) نشان می دهیم در حالت بهینه (یعنی زمانی که discriminator به صورت بهینه عمل کند) تابع هدف تبدیل به اختلاف بین شتون بین P و Q_θ می شود

۵

$$\mathbb{E}_{x,z} [2 \log P(z|x)] = \int P(x) \times \frac{1}{2} \times 2 \times \log p(0|x) + Q_\theta(x) \times \frac{1}{2} \times 2 \times \log p(1|x) dx$$

اگر قرار دهیم $D(x) = p(0|x)$ (در واقع فرضی discriminator را تعریف می کنیم) به واقعی بودن تصویر نسبت می دهد) خواهیم داشت:

$$L = \int P(x) \log D(x) + Q_\theta(x) \log (1 - D(x)) dx$$

D بهینه برای هر x را می توان با مشتق گرفتن از عبارت بالا و برابر صفر گذاشتن پیدا کرد.

$$\frac{P(x)}{D(x)} - \frac{Q_\theta(x)}{1-D(x)} = 0 \Rightarrow P(x) - P(x)D(x) - Q_\theta(x)D(x) = 0 \Rightarrow D^*(x) = \frac{P(x)}{P(x) + Q_\theta(x)}$$

با قرار دادن D بهینه در L داریم:

$$L = \int P(x) \log \frac{P(x)}{P(x) + Q_\theta(x)} + Q_\theta(x) \log \frac{Q_\theta(x)}{P(x) + Q_\theta(x)} dx$$

ابتدا اختلاف JS را می نویسیم تا شباهتشان را ببینیم:

$$f(x) = x \log \frac{2x}{x+1} + \log \frac{2}{x+1} \Rightarrow JS(P||Q_\theta) = D_f(P, Q)$$

$$\Rightarrow JS(P||Q_\theta) = \int P(x) \log \frac{2P(x)}{P(x) + Q_\theta(x)} + Q_\theta(x) \log \frac{2Q_\theta(x)}{P(x) + Q_\theta(x)} dx$$

(البته فرضی JS را $\frac{1}{4}$ این مقدار می گیرند)

پس داریم:

$$L = JS(P||Q_\theta) + \int P(x) \log \frac{1}{2} + Q_\theta(x) \log \frac{1}{2} dx$$

$$\Rightarrow L = JS(P||Q_\theta) - 2 \log 2$$

(۳) با توجه به روابطی که برای $D(x)$ بهینه و تابع هدف به ازای آن به دست آوردیم، شبکه‌ی مولد برای آن که بتواند شبکه‌ی Discriminator را فریب بدهد لازم است توزیع Q_θ را کاملاً شبیه کند؛ یا به عبارتی $Q_\theta = P$ کند.

آموزش یک GAN را می‌توان به صورت زیر نوشت:

$$\min_{\theta} \max_D \int_x p(x) \log D(x) + Q_\theta(x) \log (1 - D(x)) dx$$

$$= \min_{\theta} \max_D E_{x \sim P} [\log D(x)] + E_{x \sim Q_\theta} [\log (1 - D(x))]$$

که در آن $D(x) = P(Z=0 | x)$ است.

$$R_{\phi}(f) = \mathbb{E}_{XY} [\phi(f(X)Y)] = \mathbb{E}_X \mathbb{E}_{Y|X} [\phi(f(X)Y)]$$

(1) سوال (6)

$$= \mathbb{E}_X [\phi(f(X)) P[Y=1|X=x] + \phi(-f(X)) P[Y=-1|X=x]]$$

$$= \mathbb{E}_X [\phi(f(X)) \eta(x) + \phi(-f(X)) (1-\eta(x))]$$

$$\Rightarrow \ell_{\phi}(x, y) = \phi(x)y + \phi(-x)(1-y)$$

فرم جمع ℓ_{ϕ}

(2) از $D_f(P_1 \| P_{-1})$ شروع می کنیم و نشان می دهیم که برابر با $R_{\text{prior}, \phi}^* - R_{\phi}^*$ است

$$f(t) = \ell_{\phi}^*(\pi) (t\pi + 1 - \pi) - \inf_{\alpha} \pi \phi(\alpha) t + (1-\pi) \phi(-\alpha)$$

$$\Rightarrow D_f(P_1 \| P_{-1}) = \mathbb{E}_{\frac{P_1}{P_{-1}}} [f(\frac{P_1}{P_{-1}})]$$

$$= \mathbb{E}_{\frac{P_1}{P_{-1}}} \left[\inf_{\alpha} \left(\pi \phi(\alpha) + \phi(-\alpha)(1-\pi) \right) \left(\frac{P_1^{(n)}}{P_{-1}^{(n)}} \pi + 1 - \pi \right) \right]$$

$\ell_{\phi}^*(\pi)$

$$= \mathbb{E}_{P_{-1}} \left[\inf_{\alpha} \left(\pi \phi(\alpha) \frac{P_1^{(n)}}{P_{-1}^{(n)}} \pi + (1-\pi) \phi(-\alpha) \right) \right]$$

$$= \sum_x \left[\inf_{\alpha} \pi \phi(\alpha) + \phi(-\alpha)(1-\pi) \right] \left(\frac{P_1(x) \pi + P_{-1}(x)(1-\pi)}{\sum_y P_x(y) P_y(y) = P_x} \right) = R_{\text{prior}, \phi}^*$$

$R_{\text{prior}, \phi}^*$

به ازای x و α وابسته نیست و بیرون می آید

$$- \sum_x \left[\inf_{\alpha} \pi \phi(\alpha) P_1(x) + (1-\pi) \phi(-\alpha) P_{-1}(x) \right] \rightarrow$$

$$\hookrightarrow = \inf_{x \rightarrow \mathbb{R}} \sum_n \pi \phi(f(x)) P_1(x) + (1-\pi) \phi(-f(x)) P_{-1}(x)$$

$$= \inf_{x \rightarrow \mathbb{R}} \sum_n \sum_y P(x, y) \phi(f(x)y) = R_{\phi}^*$$

به ازای هر x ، یک α می بینیم پیدا می کنیم مانند این است که یک تابع می بینیم یا نه

$$\Rightarrow D_f(P_1 \| P_{-1}) = R_{\text{prior}, \phi}^* - R_{\phi}^*$$

(4)

$$R_{\text{prior}, \phi}^* = \inf_{\alpha} P(Y=1) \phi(\alpha) + P(Y=-1) \phi(\alpha)$$

$$= \inf_{\alpha} P(Y=1) \log(1+e^{\alpha}) + P(Y=-1) \log(1+e^{-\alpha})$$

به طور کلی \inf عبارت $p \log(1+e^{\alpha}) + \bar{p} \log(1+e^{-\alpha})$ نسبت به α است.
 که در بخش بعدی آن استفاده کنیم.

$$\inf_{\alpha} p \log(1+e^{\alpha}) + \bar{p} \log(1+e^{-\alpha})$$

$$\Rightarrow \frac{d}{d\alpha} = 0 \Rightarrow p \times \frac{e^{\alpha}}{1+e^{\alpha}} + \bar{p} \times \frac{-e^{-\alpha}}{1+e^{-\alpha}} = \frac{1}{1+e^{\alpha}} (pe^{\alpha} - \bar{p}) = 0$$

$$\Rightarrow e^{\alpha} = \frac{\bar{p}}{p} = \frac{-1}{e^{\alpha} + 1}$$

$$\Rightarrow \inf = p \log\left(1 + \frac{\bar{p}}{p}\right) + \bar{p} \log\left(1 + \frac{p}{\bar{p}}\right) = p \log\left(\frac{1}{p}\right) + \bar{p} \log\left(\frac{1}{\bar{p}}\right)$$

$$\Rightarrow R_{\text{prior}, \phi}^* = P(Y=1) \log \frac{1}{P(Y=1)} + P(Y=-1) \log \frac{1}{P(Y=-1)} = H(Y)$$

$$R_{\phi}^* = \sum_{\mathbf{x}} p(\mathbf{x}) \times \left[\inf_{\alpha} \phi(\alpha) p[Y=1|\mathbf{x}] + \phi(-\alpha) p[Y=-1|\mathbf{x}] \right]$$

$$= \sum_{\mathbf{x}} p(\mathbf{x}) \left(p[Y=1|\mathbf{x}] \log \frac{1}{p[Y=1|\mathbf{x}]} + p[Y=-1|\mathbf{x}] \log \frac{1}{p[Y=-1|\mathbf{x}]} \right)$$

$$= \sum_{\mathbf{x}} p(\mathbf{x}) H(Y|X=\mathbf{x}) = \mathbb{E}_{\mathbf{x}} [H(Y|X)] \Leftrightarrow$$

$$R_{\text{prior}, \phi}^* - R_{\phi}^* = \mathbb{E}_{\mathbf{x}} [H(Y|X)] - H(Y) = I(X; Y) \quad \text{مقدار ثابت شد}$$

سوال (۷)

(۱) نشان می دهیم تخمینگری وجود دارد که خطای از $\log p$ می گزید. پس بهترین تخمینگر از خطای بیش کمتر مساوی خواهد بود.

تخمین گری که ارائه می کنیم، بیشترین مقدار X خواهد بود.

$$T(x) = \max_i x_i$$

$$\Rightarrow \mathbb{E}_\theta [(\theta_{\max} - X_{\max})^2] = \mathbb{E}_\theta [\|X - \theta\|_\infty^2]$$

$$X - \theta \sim N(0, 1) \Rightarrow \mathbb{E}_{Z \sim N(0, 1)} [\|Z\|_\infty^2] \approx c \log p$$

(این موضوع که نرم بی نهایت یک متغیر گارسی، اسید ریاضی از $\log n$ دارد معروف است و می توانستیم آن را اثبات کنیم)

پس با گرفتن T می ممکن به خطای بهتری می رسم و می توان گفت:

$$\inf_T \sup_\theta \mathbb{E}_\theta [(\theta_{\max} - T)^2] \lesssim \log p \quad \text{or} \quad \leq c \log p$$

(۲) برای اثبات این بخش از روش «نقطه ای Le-Cam» استفاده می کنیم

θ_0 را بردار صفر انتخاب می کنیم و بردار θ را به صورت یکنواخت از $\{\sqrt{s}e_1, \dots, \sqrt{s}e_p\}$ انتخاب می کنیم (چون فقط درایه \max برایمان مهم است بردار θ را برداری یکدستی مختصات در نظر گرفتیم). حال داریم:

$$|\theta_1 - \theta_0| = \rho(\theta_1, \theta_0) = \sqrt{s} \quad \phi(x) = x^2$$

$$\Rightarrow \min \max \geq \phi(s) \times \frac{1}{p} (1 - TV(\rho_{\theta_1}, \rho_{\theta_0})) \geq \frac{1}{p} s^2 \times \frac{1}{p} (1 - \sqrt{\frac{1}{p} \chi^2(\rho_{\theta_1}, \rho_{\theta_0})})$$

$$\chi^2(\rho_{\theta_1}, \rho_{\theta_0}) = \mathbb{E}_{\theta_1, \hat{\theta}_1 \sim \pi} \left[\int \frac{\rho_{\theta_1}(x) \rho_{\hat{\theta}_1}(x)}{\rho_{\theta_0}(x)} dx \right] - 1$$

توزیع یکنواخت روی $\sqrt{s}e_i$

$$= \mathbb{E}_{\theta, \hat{\theta}} \left[\int \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\|x - (\hat{\theta}_1 + \theta)\|^2}{2}\right) \exp(\langle \theta_1, \hat{\theta}_1 \rangle \times \frac{x}{p}) dx \right] - 1$$

$$= \mathbb{E}_{\theta, \hat{\theta}} [\exp(\langle \theta_1, \hat{\theta}_1 \rangle)] - 1 = \frac{1}{p} \times \exp(\epsilon s^2) + (1 - \frac{1}{p}) \times \exp(0) - 1 = \frac{1}{p} \exp(\epsilon s^2) - \frac{1}{p}$$

احتمال اینکه درایه θ صفر نباشد

$$\min \max \geq \frac{\delta^2}{4} \left(1 - \sqrt{\frac{1}{4} \times \frac{\exp(\epsilon \delta^2) - 1}{p}} \right)$$

بنابراین داریم،

$$\sqrt{\frac{1}{4} \times \frac{\exp(\epsilon \delta^2) - 1}{p}} = c \Rightarrow \epsilon \delta^2 = c \log p$$

$$\Rightarrow \min \max \geq \frac{\delta^2}{4} \times c = c \log p$$

تخمین گری نزدیک بخش قبل ارائه دادیم که ضیق خطای دارد. پس این لدر برای خطای $\min \max$ tight است.

سوال (۱)

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^d |y_i - \theta_i|^2 + \lambda \mathbb{1}[\theta_i \neq 0]$$

$$\Rightarrow \hat{\theta}_i = \underset{\theta_i}{\operatorname{argmin}} |y_i - \theta_i|^2 + \lambda \mathbb{1}[\theta_i \neq 0]$$

$$\begin{cases} \theta = 0 \rightarrow \text{loss}_i = y_i^2 \\ \theta \neq 0 (\theta = y_i) \rightarrow \text{loss}_i = \lambda \end{cases} \Rightarrow \begin{cases} y_i^2 > \lambda \rightarrow \theta = y_i \\ y_i^2 \leq \lambda \rightarrow \theta = 0 \end{cases}$$

بنابراین $\tau = \sqrt{\lambda}$

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^d |y_i - \theta_i|^2 + \lambda |\theta_i| \Rightarrow \hat{\theta}_i = \underset{\theta_i}{\operatorname{argmin}} |y_i - \theta_i|^2 + \lambda |\theta_i|$$

(۲)

در سه حالت $\theta_i > 0$, $\theta_i < 0$, $\theta_i = 0$ متغیر می گیریم.

$$\theta_i > 0 \Rightarrow \psi(\theta_i - y_i) + \lambda = 0 \Rightarrow \theta_i = y_i - \frac{\lambda}{\psi}, \quad \theta_i > 0 \Rightarrow \boxed{y_i > \frac{\lambda}{\psi}}$$

$$\theta_i < 0 \Rightarrow \psi(\theta_i - y_i) - \lambda = 0 \Rightarrow \theta_i = y_i + \frac{\lambda}{\psi}, \quad \theta_i < 0 \Rightarrow \boxed{y_i < -\frac{\lambda}{\psi}}$$

$$\theta_i = 0 \Rightarrow \boxed{-\frac{\lambda}{\psi} \leq y_i \leq \frac{\lambda}{\psi}}$$

$$\Rightarrow \hat{\theta}_i^{ST} = \begin{cases} y_i - \frac{\lambda}{\psi} & y_i > \frac{\lambda}{\psi} \\ 0 & |y_i| \leq \frac{\lambda}{\psi} \\ y_i + \frac{\lambda}{\psi} & y_i < -\frac{\lambda}{\psi} \end{cases} \Rightarrow \boxed{\tau = \frac{\lambda}{\psi}}$$

(۳)

تا زمانی که $\tau \ll \infty$ است، می توانیم θ را صفر نگه داریم و loss صفر داشته باشیم.

هرگاه τ بزرگ شود، باید دایره های τ بزرگ تر شود. باید دایره های متناظر در θ را برابر با مقدار قرار دهیم تا $\tau < \theta_i - y_i$ شود. با توجه به اینکه تنها بجای ما مهم است که θ_i صفر است یا نه و مقدار آن مهم نیست، می توان آن را برابر با y_i گذاشت.

$$\Rightarrow \hat{\theta}_i = \begin{cases} 0 & |y_i| < \tau \\ y_i & |y_i| \geq \tau \end{cases} \Rightarrow \hat{\theta} = \theta^{HT}$$

(۴) به طور مشابه به بخش مثل، هرگاه همی درایه یی γ مقدار کمترین از γ دارند، θ_0 را صفر می‌گذاریم. اما اگر $\gamma > \gamma_0$ باشد، کمترین مقدار γ_0 برای θ_0 می‌توان مقصود شد تا قید برقرار شود. $\gamma - \gamma_0$ است. به طور مشابه اگر $\gamma < \gamma_0$ ، لازم است θ_0 را برابر $\gamma + \gamma_0$ قرار دهیم. پس θ_0^{opt} یک جواب این مسئله است.

سوال (۹)

(۱) نشان می‌دهیم: برای یک تخمین‌گر $\sup_{\theta} E_{\theta} \|\hat{\theta} - \theta\|_2^2$ از ۱ بزرگتر است. پس به ازای همی تخمین‌گر \inf_{θ} (یا \inf_{θ} روی تخمین‌گر) نیز این نامساوی برقرار خواهد بود.

تخمین‌گرمان را به این صورت طراح می‌کنیم که $\hat{\theta}_1$ را برابر با X_1 قرار می‌دهیم و بقیه درایه یی $\hat{\theta}$ را $(\hat{\theta}_1)$ را صفر می‌گذاریم. در این صورت داریم،

$$\begin{aligned} \sup_{\theta} E_{\theta} [\|X_1 - \theta_1\|_2^2 + \|\theta_{1:1}\|_2^2] \\ = E_{\theta} [|X_1 - \theta_1|^2] + \sup_{\theta} E_{\theta} [\|\theta_{1:1}\|_2^2] \end{aligned}$$

$$X_1 - \theta_1 \sim N(0, 1)$$

$$\Rightarrow E_{\theta} [|X_1 - \theta_1|^2] = E[(X_1 - \theta_1)^2] + \text{Var}(X_1 - \theta_1) = 1$$

$$\|\theta_{1:1}\|_2 \leq 2(1 - \underbrace{|\theta_1|}_{\text{مثبت}})^{-1/4} \leq 2$$

$$\Rightarrow \sup_{\theta} E_{\theta} [\|\hat{\theta} - \theta\|_2^2] = 1 + 4 = 5 \leq 1$$

ناب شد